

수술 도구 분할·끝점 주석 데이터셋 구축 결과 보고서

A Reproducible Pipeline for Constructing a Surgical-Tool Segmentation and Tip-Annotation Dataset from Endoscopic Video

- **저자(Author):** Doosik Kim
- **소속(Affiliation):** 한국전자통신연구원 (ETRI)
- **작성일(Date):** 2026-06-30
- **문서 버전(Version):** 1.0

초록 (Abstract)

본 보고서는 내시경 수술 영상으로부터 수술 도구의 의미론적 분할(semantic segmentation) 마스크와 도구 끝점(tip) 주석을 자동으로 생성하고, 이를 사람이 보정할 수 있는 재현 가능한(reproducible) 데이터셋 구축 파이프라인의 설계와 그 구축 결과를 기술한다. 파이프라인은 (1) 원본 비디오의 progressive 변환(선택), (2) 프레임 추출 및 train/val/test 분할, (3) 사전학습된 MONAI 분할 모델 다운로드, (4) 프레임별 이진 분할 마스크 추론, (5) 마스크 기반 bounding box·tip 주석의 자동 생성, (6) GUI 편집기를 통한 수동 보정의 6단계로 구성된다. 5편의 내시경 수술 영상으로부터 총 **180,706 프레임**(train 108,424 / val 36,140 / test 36,142 - 60:20:20)을 추출하였으며, 모든 프레임에 대해 분할 마스크를 생성하고 주석 JSON을 생성하였다. 자동 생성된 주석은 프레임당 평균 약 1.45개의 도구 인스턴스를 포함한다.

핵심어(Keywords): 수술 도구 분할, 끝점 검출, 내시경 영상, 데이터셋 구축, 자동 주석, MONAI, 재현 가능

1. 서론 (Introduction)

1.1 배경 및 동기

내시경·복강경 수술 영상에서 수술 도구를 인식하고 그 위치와 끝점을 추적하는 기술은 수술 단계 인식, 술기 평가, 수술 내비게이션, 로봇 보조 수술 등 다양한 응용의 핵심 기반 기술이다. 이러한 응용을 위한 학습 데이터는 (a) 도구 영역을 픽셀 단위로 표시한 분할 마스크와 (b) 도구의 끝(tip) 좌표를 포함해야 하는 경우가 많다. 그러나 수술 영상은 프레임 수가 방대하여 모든 프레임을 사람이 수작업으로 주석하는 것은 비용과 시간 측면에서 비현실적이다.

본 작업의 동기는 "**모델 기반 자동 주석으로 초안을 대량 생성하고, 사람이 필요한 부분만 보정한다**"는 반자동(semi-automatic) 전략을 실용적인 도구 모음으로 구현하는 데 있다. 즉, 완벽한 정답을 한 번에 만들기보다, 충분히 좋은 초

안을 저비용으로 대량 확보하고 검수·보정 단계로 품질을 끌어올리는 것을 목표로 한다.

1.2 목표

본 데이터셋 구축의 검증 가능한 목표는 다음과 같다.

1. 5편의 내시경 수술 영상으로부터 일관된 해상도의 프레임 데이터셋을 결정론적으로(deterministically) train/val/test로 분할하여 생성한다.
2. 모든 프레임에 대해 도구/배경 이진 분할 마스크를 생성한다.
3. 분할 마스크로부터 도구별 bounding box와 tip 좌표를 자동 산출하여 표준화된 JSON 주석을 생성한다.
4. 자동 주석을 사람이 검수·수정할 수 있는 GUI 도구와, 전체 단계를 일괄 실행·점검할 수 있는 통합 GUI를 제공한다.
5. 동일 입력·동일 설정에서 결과가 재현되도록 파이프라인의 전체 단계를 결정론적으로 구성한다.

1.3 기여

- 비디오 → 프레임 → 마스크 → 주석 → 보정으로 이어지는 **종단간(end-to-end) 데이터셋 구축 파이프라인**을 모듈화된 스크립트와 런처, GUI로 구현하였다.
- 분할 마스크의 contour 기하로부터 도구 tip을 추정하는 **경량 휴리스틱**을 제안·구현하였다.
- 5편 영상, **180,706 프레임** 규모의 분할·tip 주석 데이터셋을 구축하고 그 통계적 특성을 보고하였다.

2. 배경 및 관련 도구 (Background)

2.1 수술 도구 분할 모델

본 파이프라인은 분할 추론에 MONAI(Medical Open Network for AI)에서 공개한 사전학습 모델 MONAI/endoscopic_tool_segmentation 을 사용한다. 네트워크 구조는 MONAI의 FlexibleUNet 이며, EfficientNet-B2 백본을 인코더로 사용하는 2차원 U-Net 계열의 인코더-디코더 구조이다. 출력은 2채널(배경/도구)이며, 채널 방향 argmax를 통해 이진 마스크로 변환된다. 모델 가중치는 별도 학습 없이 그대로 추론에 사용된다(전이 추론, inference-only).

2.2 끝점(tip) 추정의 관점

수술 도구는 일반적으로 화면 가장자리에서 진입하여 화면 중앙의 수술 부위를 향한다. 따라서 도구 영역(길쭉한 형태)의 양 끝점 중 **화면 중심에 더 가까운 쪽**이 수술도구의 끝부분(tip)일 가능성이 높다. 본 작업은 이 관찰을 단순한 기하 규칙으로 형식화하여, 분할 마스크의 contour만으로 tip을 추정한다(3.5절).

2.3 재현성·결정성 원칙

데이터셋의 신뢰성을 위해 파이프라인은 전역 난수에 의존하지 않고, 비디오 경로와 시드로부터 유도한 비디오별 독립 난수 생성기로 분할을 결정한다. 또한 주석 직렬화 시 키 정렬과 인스턴스 정렬을 고정하여, 동일 입력에 대해 바이트 단위로 동일한 산출물이 나오도록 한다.

3. 데이터셋 구축 방법 (Methods)

3.1 파이프라인 개요

전체 파이프라인은 6단계로 구성되며, 각 단계는 독립 실행 가능한 스크립트(`scripts/*.py`)와 셀 런처(`bin/*`)로 제공된다. 통합 GUI(`scripts/pipeline.py`)는 이 단계들을 버튼으로 실행하고 진행 상태와 로그를 표시한다.

단계	모듈	입력	출력
1. Progressive 변환	<code>generate_progressive.py</code>	<code>data/video/</code>	<code>data/progressive/</code>
2. 프레임 추출·분할	<code>generate_dataset.py</code>	<code>data/progressive/</code>	<code>data/dataset/images/{split}/</code>
3. 모델 다운로드	<code>download_model.py</code>	HuggingFace Hub	<code>temp/models/model.pt</code>
4. 분할 마스크 생성	<code>generate_segmentation.py</code>	<code>images/</code> + 모델	<code>data/dataset/segmentation/{split}/</code>
5. 주석 자동 생성	<code>generate_annotation.py</code>	<code>segmentation/</code>	<code>data/dataset/annotation/{split}/</code>
6. 수동 보정	<code>annotation_editor.py</code>	이미지+마스크+주석	보정된 <code>annotation/</code>

여기서 `{split}` ∈ `{train, val, test}` 이다.

3.2 원본 동영상 데이터 (1단계)

원본 동영상 데이터는 5편의 내시경 수술 영상이며, 파일명 규칙은 `doctor_<YYMMDD>_<HHMMSS>.mp4` 이다. 파일명에 기록된 촬영 일자는 2025-06-20(2편), 2025-07-02(2편), 2025-07-23(1편)이다.

원본 동영상이 인터레이스(interlace) 형식일 경우 `ffmpeg` 라이브러리를 이용하여 `progressive` 형식으로 재인코딩해야 한다. 사용된 변환 파라미터는 다음과 같다.

- 디인터레이스 필터: `yadif`
- 비디오 코덱: `libx264` , `-crf 20` (시각적 무손실에 가까운 고품질 설정)
- 오디오: `-c:a copy` (재인코딩 없이 복사)

이 단계는 후속 프레임 추출이 깨끗한 `progressive` 프레임 위에서 수행되도록 보장한다.

3.3 프레임 추출 및 분할 (2단계)

progressive 영상에서 **10프레임마다 1장**(`--frame 10`)을 추출한다. 추출된 각 프레임은 원본 종횡비를 유지한 채 letterbox 방식으로 **736×480**(너비×높이)에 맞추어 리사이즈되고, 부족한 영역은 검은색으로 패딩되어 PNG로 저장된다. 따라서 입력 영상의 해상도·종횡비와 무관하게 모든 출력 프레임은 동일한 736×480 해상도를 가진다.

분할(train/val/test) 비율은 기본값 **60:20:20**이다. 분할은 전체 데이터셋을 한 번에 섞는 방식이 아니라, **비디오마다 독립적으로** 수행된다. 이를 위해 각 비디오 경로와 시드(`--seed 0`)를 blake2b 해시로 결합하여 비디오별 독립 난수 생성기를 만들고, 그 비디오의 추출 프레임을 셔플하여 비율대로 배분한다. 이 설계 덕분에 모든 비디오가 거의 동일한 비율로 세 분할에 기여하며, 동일 입력·동일 시드에서 분할 결과가 재현된다.

파일명 규칙은 <영상이름>_<프레임번호 8자리>.png 이다(예: doctor_250620_084707_00000000.png).

3.4 분할 마스크 생성 (3·4단계)

3단계에서 MONAI/endoscopic_tool_segmentation 체크포인트(models/model.pt)를 HuggingFace Hub에서 내려받는다. 4단계에서는 이 모델로 각 프레임을 추론한다. 추론 절차는 다음과 같다.

1. 프레임을 RGB로 읽어 모델 입력 크기(너비 736 × 높이 480)로 리사이즈하고 `[0,1]` 로 정규화한다.
2. FlexibleUNet (EfficientNet-B2 백본, 2클래스)으로 로짓을 추론한다.
3. 채널 방향 argmax로 클래스 인덱스를 얻고, 255를 곱해 0/255 이진 마스크를 만든다.
4. 마스크를 최근접 보간(`INTER_NEAREST`)으로 **원본 프레임 해상도**(736×480)로 복원하여 단일 채널 PNG로 저장한다.

디바이스는 기본적으로 CUDA가 가용하면 GPU를, 아니면 CPU를 자동 선택한다. 추론은 `torch.inference_mode()` 에서 수행되며, 모델은 한 번만 로드되어 모든 분할에 재사용된다.

3.5 주석 자동 생성 (5단계)

5단계는 이진 마스크로부터 도구별 주석을 산출한다. 핵심 절차는 다음과 같다.

1. **Contour 추출:** `cv2.findContours` 를 `RETR_EXTERNAL` (최외곽 윤곽만)·`CHAIN_APPROX_NONE` (모든 경계점 보존)으로 적용하여 도구 영역의 외곽선을 얻는다.
2. **Bounding box:** 각 contour의 축 정렬 외접 사각형 (x, y, width, height) 를 계산한다.
3. **Tip 추정(휴리스틱):**
 - contour의 무게중심을 구한다.
 - 무게중심에서 가장 먼 점 A 를 찾는다.
 - A 에서 가장 먼 점 B 를 찾는다. (A , B 는 길쭉한 영역의 양 끝 극점)
 - A 와 B 중 **영상 중심에 더 가까운 점**을 tip으로 선택한다.
4. **정렬·직렬화:** 인스턴스를 bbox의 (x, y, w, h) 순으로 정렬하고, 키 정렬(`sort_keys=True`)로 JSON을 저장한다.

모든 거리 비교는 제곱 거리로 수행하여 불필요한 제곱근 연산을 피하며, 무게중심 계산이 퇴화하는 경우(면적 0)에는 좌표 평균으로 대체하여 0 나눗셈을 방지한다. 도구가 없는 프레임은 빈 annotations 배열을 가진 JSON으로 저장된다.

다.

출력 JSON 스키마는 다음과 같다.

```
{
  "image": "doctor_250620_084707_00000030.png",
  "width": 736,
  "height": 480,
  "annotations": [
    { "bbox": {"x": 120, "y": 64, "width": 88, "height": 152},
      "tip": {"x": 150, "y": 200} }
  ]
}
```

3.6 수동 보정 도구 (6단계)

annotation_editor.py 는 tkinter 기반 GUI로, 자동 생성된 주석을 사람이 검수·수정할 수 있게 한다. 주요 기능은 split 전환, 이미지 선택, 분할 마스크 오버레이 표시(Show Segmentation), 주석 표시 토글(Show Annotation), bbox 이동·리사이즈, tip 드래그 수정, 주석 추가·삭제, 저장(Save / Ctrl+S)이다. 저장 형식은 자동 생성 단계와 동일한 스키마를 따르므로, 보정 결과가 파이프라인과 호환된다.

3.7 통합 파이프라인 GUI

pipeline.py 는 6단계를 하나의 창에서 실행·점검하는 통합 GUI다. 각 단계 버튼은 bin/<단계> 런처(내부적으로 uv run python -m scripts.<단계>)를 자식 프로세스로 실행하고, 표준 출력/오류를 실시간 로그로 표시한다. 또한 data/ · temp/ 디렉터리의 파일 개수를 세어 각 단계의 진행 상태(완료/부분/대기 등)를 아이콘으로 시각화한다. 다만 이 GUI는 각 단계를 **인자 없이** 실행하므로 기본 옵션으로만 동작하며, 강제 재생성(--overwrite)이나 디바이스 지정 등은 CLI 실행이 필요하다.

4. 데이터셋 구성 및 통계 (Results)

본 절의 수치는 작성일(2026-06-30) 기준 산출물 스냅샷에서 직접 집계한 값이다. 일부 통계는 계산 비용을 고려해 무작위 표본(시드 고정)으로 추정하였으며, 해당 부분에 표본 크기를 명시하였다.

4.1 전체 규모 및 분할

총 추출 프레임 수는 **180,706장**이며, train/val/test 비율은 정확히 60.00 : 20.00 : 20.00이다.

분할	이미지	분할 마스크	주석 JSON	비율
train	108,424	108,424	108,424	60.00%
val	36,140	36,140	36,140	20.00%

분할	이미지	분할 마스크	주석 JSON	비율
test	36,142	36,142	36,142	20.00%
합계	180,706	180,706	180,706	100%

4.2 영상별 프레임 분포

5편 영상이 기여한 프레임 수와 각 분할로의 배분은 다음과 같다. 모든 영상이 약 60:20:20 비율로 세 분할에 고르게 기여함을 확인할 수 있다.

원천 영상	합계	train	val	test
doctor_250620_084707	24,010	14,406	4,802	4,802
doctor_250620_131843	27,081	16,249	5,416	5,416
doctor_250702_084355	18,608	11,165	3,721	3,722
doctor_250702_101536	76,988	46,193	15,397	15,398
doctor_250723_094100	34,019	20,411	6,804	6,804
합계	180,706	108,424	36,140	36,142

단일 영상(doctor_250702_101536)이 전체의 약 42.6%를 차지하여 영상 간 분포는 불균형하다(4.5절 한계 참조).

4.3 해상도

모든 이미지·마스크·주석 메타에서 해상도는 **736×480**으로 일관됨을 확인하였다(표본 검사 결과 단일 해상도). 이는 letterbox 리사이즈 설계(3.3절)와 일치한다.

4.4 주석 통계

자동 생성된 주석의 특성을 분할별 표본(각 4,000장) 및 통합 표본(12,000장)으로 분석하였다.

(a) 프레임당 도구 인스턴스 수. 분할별 평균은 train 1.456, val 1.452, test 1.450개로 거의 동일하며, 도구가 없는 빈 프레임 비율은 약 13.8~14.8%였다.

분할	표본	평균 도구 수	최대 도구 수	빈 프레임 비율
train	4,000	1.456	8	14.4%
val	4,000	1.452	8	14.8%
test	4,000	1.450	10	13.8%

통합 표본(12,000장)에서의 프레임당 도구 수 분포는 다음과 같다. 대부분의 프레임이 0~3개의 도구를 포함하며, 드물게 10개 이상이 검출되었다.

도구 수	0	1	2	3	4	5	6	7	8	9	10	16
프레임	1,693	5,131	3,627	1,180	289	62	8	4	1	3	1	1

다수의 작은 영역(예: 16개)이 한 프레임에서 검출되는 경우는 마스크 노이즈로 인한 과분할(over-segmentation) 가능성을 시사한다(4.5절).

(b) Bounding box 크기. 통합 표본 기준 bbox의 평균 크기는 192×135 픽셀(중앙값 170×123)이며, 평균 면적은 프레임 전체의 약 **9.1%** 였다. 도구가 화면에서 차지하는 비중이 비교적 작고 길쭉한 형태임을 보여준다.

5. 품질 관리 및 엔지니어링 이슈 (Quality Control & Engineering Notes)

5.1 결정성과 재실행 안전성

- **분할 결정성:** 비디오별 blake2b 시드로 분할이 결정되어, 동일 입력·시드에서 분할 결과가 재현된다.
- **직렬화 결정성:** 주석은 인스턴스 정렬과 키 정렬이 고정되어, 동일 마스크에 대해 바이트 단위로 동일한 JSON이 생성된다(버전 관리 친화적).
- **건너뛰기/덮어쓰기 정책:** 분할·주석 단계는 기본적으로 기존 산출물을 건너뛰며, 전부 존재하면 작업 없이 조기 종료한다. 재생성은 `--overwrite` 로 명시해야 한다.

5.2 자동 주석의 내재적 한계

- tip 추정은 휴리스틱이므로, 도구가 짧거나 화면 중앙을 가로지르거나 마스크가 부정확한 경우 실제 tip과 다를 수 있다.
- contour 면적에 대한 최소 임계값이 없어, 마스크 노이즈가 작은 가짜 인스턴스로 잡힐 수 있다(4.4절의 다수 인스턴스 사례).
- `RETR_EXTERNAL` 만 사용하므로 서로 겹치거나 닿아 있는 도구가 하나의 영역으로 병합될 수 있다.
- 좌표가 정수로 저장되어 서브픽셀 정밀도는 유지되지 않는다.

이러한 한계는 6단계 수동 보정으로 교정하는 것을 전제로 한다.

6. 한계 및 향후 과제 (Limitations & Future Work)

6.1 데이터셋 측면의 한계

1. **영상 다양성:** 5편의 영상에서만 추출되었고, 단일 영상이 전체의 약 42.6%를 차지하여 분포가 불균형하다. 또한 분할이 영상 단위가 아니라 영상 내부에서 이뤄지므로, 동일 영상의 인접 프레임이 train과 test에 동시에 존재할

수 있다(시간적 누수, temporal leakage 가능성).

2. **자동 주석의 미검증성:** 본 보고서의 주석 통계는 분포 특성에 대한 기술 통계이며, 사람이 검수한 정답 대비 정확도(IoU, tip 픽셀 오차 등)는 측정되지 않았다.

6.2 향후 과제

1. 영상 단위 분할(video-level split) 옵션을 도입하여 시간적 누수를 차단한다.
2. 자동 주석에 대한 사람 검수 표본을 확보하여 IoU·tip 오차 등 정량 지표를 산출하고, 휴리스틱을 보정·평가한다.
3. 최소 면적 임계값, 다중/중첩 도구 분리, 클래스(도구 종류) 라벨 확장 등으로 주석 스키마와 추출 로직을 강화한다.
4. 분할 단계에 배치 추론을 도입하여 18만 장 규모의 처리량을 개선한다.
5. 모델 입력 크기를 코드 상수가 아닌 설정으로 외부화하여, 해상도 변경 시 결함 재발을 방지한다.

7. 결론 (Conclusion)

본 보고서는 내시경 수술 영상으로부터 수술 도구의 분할 마스크와 tip 주석을 자동 생성·보정하는 재현 가능한 데이터셋 구축 파이프라인과 그 결과를 기술하였다. 5편의 영상으로부터 **180,706 프레임**을 정확히 60:20:20으로 분할하여 전 프레임에 대한 분할 마스크와 주석 커버리지를 확보하였다. 자동 주석은 프레임당 평균 약 1.45개의 도구를 포함하며, tip 분포는 설계 휴리스틱과 정성적으로 일치하였다. 본 결과물은 자동 초안 + 사람 보정이라는 반자동 전략의 실용적 토대를 제공하며, 향후 영상 단위 분할, 정량 평가, 스키마 확장 등을 통해 학습용 데이터셋으로서의 완성도를 높일 수 있다.

부록 A. 디렉터리 구조 (Directory Layout)

```
data/
├─ video/                # 원본 영상 (5편)
├─ progressive/          # progressive 변환본 (5편)
└─ dataset/
    ├─ images/{train,val,test}/    # 736×480 PNG 프레임 (180,706장)
    ├─ segmentation/{train,val,test}/ # 0/255 이진 마스크 PNG (180,706장)
    └─ annotation/{train,val,test}/ # bbox/tip 주석 JSON (180,705개)
temp/
└─ models/model.pt        # MONAI 분할 모델 체크포인트
```


부록 B. 재현 절차 (Reproduction)

```
# 0) 의존성
uv sync

# 1) progressive 변환
uv run python -m scripts.generate_progressive

# 2) 프레임 추출·분할 (기본 736x480, 60/20/20, frame=10, seed=0)
uv run python -m scripts.generate_dataset

# 3) 모델 다운로드
uv run python scripts/download_model.py

# 4) 분할 마스크 생성 (재생성 시 --overwrite)
uv run python -m scripts.generate_segmentation --device cuda:0 --overwrite

# 5) 주석 자동 생성 (재생성 시 --overwrite)
uv run python -m scripts.generate_annotation --overwrite

# 6) 수동 보정 GUI
uv run python -m scripts.annotation_editor

# (선택) 통합 GUI
uv run python -m scripts.pipeline
```

부록 C. 주요 구성 파라미터 (Configuration Summary)

항목	값
디인터레이스	ffmpeg yadif
비디오 코덱	libx264 , CRF 20
프레임 추출 간격	10 프레임당 1장
출력 해상도	736 × 480 (letterbox)
스플릿 분할 비율	train 60 / val 20 / test 20
스플릿 분할 시드	0 (비디오별 blake2b 유도)
영상 분할 모델	MONAI/endoscopic_tool_segmentation
네트워크 구조	FlexibleUNet, EfficientNet-B2 백본, 2클래스
모델 입력 크기	736 × 480
마스크 이진화	임계값 127 → 0/255
tip 규칙	양 끝 극점 중 영상 중심에 가까운 점

항목	값
주석 직렬화	JSON, indent=2, sort_keys=true

부록 D. 산출물 스냅샷 집계 방법 (Data Provenance)

- 전체·분할별 파일 수: 디렉터리 전수 집계(2026-06-30 기준).
- 도구 수·tip·bbox 통계: 시드 고정 무작위 표본(분할별 4,000장, 통합 12,000장)으로 추정.

본 보고서는 `tooltip-annotator` 저장소의 코드와 `docs/` 문서, 그리고 작성일 기준 산출물 스냅샷에 근거하여 Claude Sonnet 5로 작성하였다. 자동 주석의 정량적 정확도 평가는 본 보고서의 범위를 벗어나며 향후 과제로 남긴다.