

복강경 수술 영상에서의 거리 기반 히트맵 회귀를 이용한 수술도구 팁 탐지

실험결과보고서

- 저자(Author): Doosik Kim
- 소속(Affiliation): 한국전자통신연구원 (ETRI)
- 작성일(Date): 2026-06-30
- 문서 버전(Version): 1.0

초록 (Abstract)

복강경(laparoscopy) 수술 중 수술도구 끝부분(팁, tip)의 위치를 실시간으로 파악하는 일은 수술 항법(navigation), 자동 카메라 추종, 술기 분석 등 다양한 컴퓨터 보조 수술(computer-assisted surgery) 응용의 기초가 된다. 본 연구는 단일 RGB 프레임으로부터 도구 팁 위치를 추정하는 문제를, 이진 검출이나 좌표 회귀 대신 **거리 기반 히트맵 회귀(distance-based heatmap regression)** 문제로 접근하였다. 분할 마스크와 팁 좌표 어노테이션을 결합하여, 도구 영역 내 각 화소에 팁까지의 거리에 반비례하는 연속값(0-1)을 부여한 히트맵을 학습 타겟으로 생성한다. 모델은 EfficientNet-B2 인코더와 U-Net 디코더를 결합한 분할 네트워크로, MONAI 프레임워크의 사전학습 가중치와 직접 호환되도록 모듈 명칭을 설계하여 전이 학습을 적용하였다.

복강경 수술 영상에서 추출한 **180,706 프레임**(736×480 px) 규모의 데이터셋을 영상별 결정론적 무작위 분할로 60:20:20 나누어 학습·검증·평가에 사용하였다. 단, 분할 마스크와 팁 어노테이션은 사전학습 분할 모델 추론과 contour 휴리스틱으로 생성된 반자동(semi-automatic) 라벨로, 사람이 검증한 정답(gold standard)이 아님에 유의한다. 표준 풀 모델(monai, 11.45 M 파라미터)과 인코더 깊이를 절반으로 줄인 경량 모델(monai_mini, 5.50 M 파라미터)을 동일한 조건에서 학습·평가하여 정확도와 추론 속도를 정량 비교하였다. 테스트 세트(36,142 프레임, 52,489개 GT 팁) 기준 풀 모델은 탐지 실패율 2.97 %, 10 px 이내 정밀 탐지율(Hit@10 px) 38.10 %, 50 px 이내 탐지율 80.95 %를 달성하였다. 경량 모델은 정확도가 소폭 하락(Hit@10 px 29.61 %)하는 대신 CPU 추론 속도가 forward 기준 1.35배 향상되었다. 두 모델 모두 오차 분포의 오른쪽 꼬리가 길어(평균이 중앙값의 약 3배) 소수의 심각한 오탐이 전체 정밀도를 끌어내리는 공통 패턴을 보였으며, 세션 간 성능 편차(평균 거리 25.91-55.96 px)도 컸다. 본 보고서는 이 결과를 바탕으로 모델 구조, 학습·평가 방법론, 한계 및 향후 개선 방향을 종합적으로 분석한다.

키워드: 복강경 수술, 수술도구 팁 탐지, 히트맵 회귀, EfficientNet, U-Net, 전이 학습, 모델 경량화

1. 서론 (Introduction)

1.1 연구 배경

최소 침습 수술(minimally invasive surgery)의 대표 형태인 복강경 수술은 작은 절개창을 통해 삽입한 내시경 카메라와 가늘고 긴 수술도구를 이용해 시행된다. 집도의는 체내를 직접 보지 못하고 모니터에 표시되는 2차원 영상에만 의존하므로, 영상 내에서 도구의 위치—특히 조직과 직접 상호작용하는 **팁(tip)**의 위치—를 정확히 파악하는 일이 술기의 정밀도와 안전성에 직결된다.

수술도구 팁 위치를 자동으로 추정할 수 있다면 다음과 같은 응용이 가능해진다.

- **자동 카메라 추종**: 도구 팁을 화면 중심에 유지하도록 카메라(또는 로봇 암)를 제어
- **술기 분석 및 평가**: 도구 궤적·움직임 정량화를 통한 수술 술기 학습·평가
- **증강 현실 항법**: 도구-해부 구조 간 상대 위치를 시각적으로 보조
- **이상 상황 감지**: 도구의 비정상적 움직임이나 위험 구역 접근 경고

1.2 문제 정의와 접근

수술도구 팁 탐지는 일반적으로 다음 세 가지 방식으로 접근할 수 있다.

1. **직접 좌표 회귀(coordinate regression)**: 네트워크가 (x, y) 좌표를 직접 출력. 도구 개수가 가변적이고 다중 인스턴스 매칭이 어렵다.
2. **객체 검출(object detection)**: 바운딩 박스 기반. 팁은 점(point) 객체이므로 박스 표현이 부자연스럽다.
3. **히트맵 회귀(heatmap regression)**: 팁 위치를 공간 히트맵의 피크로 인코딩. 인체 자세 추정(pose estimation) 등에서 널리 쓰이며, 가변 개수의 점을 자연스럽게 다룬다.

본 프로젝트는 세 번째 접근을 채택하되, 일반적인 가우시안 히트맵이 아니라 **도구 분할 마스크의 형태 정보를 활용한 거리 기반 히트맵**을 도입한 것이 핵심 차별점이다. 도구는 길쭉한 형태를 가지므로, 팁에서 멀어질수록 (즉 도구 몸통 쪽으로 갈수록) 값이 선형으로 감소하는 그래디언트를 마스크 전체에 부여한다. 이로써 (i) 학습 신호가 도구 영역 전반에 분포해 학습이 안정화되고, (ii) 팁 부근에 최댓값이 집중되어 피크 위치가 곧 팁 위치가 되도록 유도한다.

1.3 연구 목표 및 기여

본 연구의 목표와 기여는 다음과 같다.

- **(G1)** 분할 마스크와 팁 좌표를 결합한 거리 기반 히트맵 타겟 생성 방법을 정식화하고, 이를 MSE 회귀 손실로 학습하는 파이프라인을 구축한다.
- **(G2)** MONAI 사전학습 가중치와 호환되는 EfficientNet-B2 + U-Net 분할 네트워크를 구현하고 복강경 수술 데이터셋으로 파인튜닝한다.

- **(G3)** 인코더 깊이를 절반으로 줄인 경량 모델을 설계하여, 풀 모델 대비 정확도-속도 트레이드오프를 정량 분석한다.
- **(G4)** 피크 탐지 기반 평가 프로토콜(Hit-rate, 거리 분포, 세션별 분석)을 정의하고, 두 모델의 강·약점과 향후 개선 방향을 도출한다.

2. 데이터셋 (Dataset)

2.1 구성 및 규모

데이터셋은 5편의 복강경(내시경) 수술 영상에서 추출한 총 **180,706 프레임**으로 구성된다. 원본 영상에서 **10 프레임마다 1장**을 추출하고, 각 프레임을 원본 종횡비를 유지한 letterbox 방식으로 736 × 480 px에 맞춰 리사이즈(부족한 영역은 검은색 패딩)하여 PNG로 저장하였다. 따라서 입력 영상의 해상도·종횡비와 무관하게 모든 프레임은 동일한 736 × 480 px RGB 해상도를 가진다. 각 프레임에는 RGB 이미지, 이진 분할 마스크(PNG, 0=배경 / 255=도구), 도구별 팁 좌표 및 바운딩 박스 어노테이션(JSON)이 대응한다.

어노테이션 생성 방식: 본 데이터셋의 분할 마스크와 팁·바운딩 박스 어노테이션은 사람이 수작업으로 라벨링한 것이 아니라 **반자동(semi-automatic) 파이프라인**으로 생성되었다. 분할 마스크는 사전학습된 MONAI 분할 모델(MONAI/endoscopic_tool_segmentation , FlexibleUNet + EfficientNet-B2 백본)을 별도 학습 없이 추론(inference-only)하여 얻은 결과이며, 팁·바운딩 박스는 이 마스크의 contour 기하로부터 휴리스틱(무게중심에서 가장 먼 두 극점을 구한 뒤, 그중 영상 중심에 더 가까운 점을 팁으로 선택)으로 자동 산출되었다. 이 어노테이션은 사람의 검수·보정을 전제로 한 **초안**이며, 사람이 검증한 정답 대비 정량적 정확도(IoU, 팁 픽셀 오차 등)는 측정되지 않았다. 따라서 본 보고서에서 'GT(ground truth)'로 지칭하는 팁 좌표는 엄밀한 의미의 검증된 정답이 아니라 이 자동 생성 어노테이션을 기준값으로 사용한 것임에 유의해야 한다(§7 한계 참조).

표 1. 데이터셋 스플릿 구성

스플릿	프레임 수	비율
train	108,424	60 %
val	36,140	20 %
test	36,142	20 %
합계	180,706	100 %

2.2 영상 구성과 영상별 무작위 분할

데이터는 5편의 영상(총 11시간 36분 분량)에서 추출되었으며, 각 영상은 세 스플릿 모두에 약 60:20:20 비율로 기여한다(표 2). 분할은 전체 프레임을 한꺼번에 쉼의 방식이 아니라 **영상마다 독립적으로** 수행되며, 각 영상

경로와 시드를 blake2b 해시로 결합한 영상별 난수 생성기로 추출 프레임을 무작위 셔플한 뒤 60:20:20으로 배분한다. 이는 동일 입력·시드에서 결과가 그대로 재현되는 결정론적(deterministic) 방식이다. 다만 분할이 영상 단위가 아니라 영상 내부의 무작위 셔플로 이뤄지므로, 같은 영상의 시간적으로 인접한 프레임이 train과 test에 동시에 들어갈 수 있어 **시간적 누수(temporal leakage)의 소지가 있다**. 또한 5편 영상이 세 스플릿 모두에 공유되므로 미지의 새 영상에 대한 완전한 영상 독립 평가(leave-video-out)는 아니다(\$7 참조).

표 2. 세션별 프레임 분포

세션 ID	train	val	test
doctor_250620_084707	14,406	4,802	4,802
doctor_250620_131843	16,249	5,416	5,416
doctor_250702_084355	11,165	3,721	3,722
doctor_250702_101536	46,193	15,397	15,398
doctor_250723_094100	20,411	6,804	6,804

세션 doctor_250702_101536 이 전체의 약 43 %를 차지하는 지배적 세션으로, 이후 평가 결과 해석에서 중요하게 작용한다.

2.3 어노테이션 특성

각 프레임의 어노테이션은 도구별 바운딩 박스(좌상단 좌표와 너비·높이)와 팁 좌표(x, y)로 구성된다. 좌표계는 좌상단을 원점으로 하며 x축은 오른쪽, y축은 아래쪽이다.

train 스플릿 기준 프레임당 도구(어노테이션 인스턴스) 수 분포는 다음과 같다(자동 생성 어노테이션을 표본 집계한 대표값).

표 3. 프레임당 도구 수 분포 (train, 자동 어노테이션 기준)

도구 수	프레임 수	비율
0 (없음)	15,616	14.4 %
1	46,458	42.9 %
2	32,635	30.1 %
3	10,495	9.7 %
4	2,416	2.2 %

도구 수	프레임 수	비율
5+	804	0.7 %

약 86 %의 프레임에 도구가 하나 이상 등장하며, 도구가 없는 프레임도 14.4 %에 달한다. 도구가 없는 프레임은 전체 타겟 히트맵이 0이 되어, 모델이 "도구가 없을 때 피크를 만들지 않는" 능력을 학습하는 음성(negative) 샘플로 기능한다. 분할 마스크와 어노테이션 JSON은 전 프레임(100 %)에 대해 생성되었고, 자동 생성 특성상 마스크 노이즈가 작은 가짜 인스턴스로 잡히는 과분할(over-segmentation) 사례가 일부 존재하며(드물게 한 프레임에서 10개 이상 검출), 표 3의 다중 도구 비율 일부는 이러한 잡음을 포함할 수 있다.

2.4 거리 기반 히트맵 타겟 생성

본 연구의 핵심 전처리는 이진 분할 마스크와 팁 좌표를 결합하여 연속 히트맵을 생성하는 과정이다. 분할 마스크 내 각 도구 화소 p 에 대해 다음과 같이 타겟값을 정의한다.

$$\text{target}(p) = 1 - \frac{\min_{t \in \text{tips}} \|p - t\|}{\max_{q \in \text{mask}} \min_{t \in \text{tips}} \|q - t\|}$$


즉, 팁 화소는 1.0, 마스크 내에서 팁으로부터 가장 먼 화소는 0.0, 그 사이는 거리에 반비례하여 선형 보간된다. 마스크 외부의 배경 화소는 0.0이며, 도구가 없는 프레임은 전체가 0.0이다. 연결요소(connected component) 별로 가장 가까운 팁을 기준으로 거리를 계산하므로, 다중 도구가 있는 프레임에서도 각 도구의 팁 근방에 독립적인 피크가 형성된다.

이 연속 그래디언트 표현은 단순 이진 마스크나 좁은 가우시안 점 히트맵에 비해, 팁 근방에 높은 학습 신호를 집중시키면서도 도구 몸통 전체로부터 풍부한 형태 정보를 학습에 활용할 수 있다는 장점이 있다.

3. 방법 (Methods)

3.1 모델 아키텍처: EfficientNet-B2 + U-Net

기본 모델 `TooltipDetector` (`monai`)는 EfficientNet-B2 인코더와 U-Net 디코더, 그리고 2채널 분할 헤드로 구성된 인코더-디코더 분할 네트워크다. 입력은 (B, 3, 480, 736), 출력은 (B, 2, 480, 736)이며, 채널 0은 배경 로짓, 채널 1은 도구 영역 로짓이다. 채널 1에 sigmoid를 적용한 값이 거리 기반 히트맵 예측에 해당한다.



인코더: EfficientNet-B2(width_coeff=1.1, depth_coeff=1.2)를 재현한다. 3×3 stride-2 스템 이후 7개 스테이지에 걸쳐 총 23개의 MBConv(Mobile Inverted Bottleneck Conv) 블록이 배치된다. 각 블록은 expand → depthwise → Squeeze-and-Excitation(SE) → project 구조에 SiLU 활성화와 잔차 연결을 포함한다. 디코더의 스킵 연결은 스테이지 0·1·2·4·6의 출력(채널 16/24/48/120/352, 공간 해상도 H/2~H/32) 5곳에서 추출된다.

디코더: U-Net 디코더는 5개의 디코더 블록으로 구성되며, 각 블록은 bilinear ×2 업샘플링 후 대응 스킵 텐서와 채널 방향 concat하고 3×3 Conv-BN-ReLU 쌍을 2회 적용한다. 마지막 블록은 스킵 없이 원본 해상도 (H×W)로 복원한다. 분할 헤드는 16채널을 2채널로 매핑하는 3×3 Conv2d다.

MONAI 호환성: 모든 모듈 명칭(encoder._conv_stem , encoder._blocks.i.j.* , decoder.blocks.k.convs.conv_0.conv , ...adn.N 등)을 MONAI FlexibleUNet(backbone="efficientnet-b2") 의 state_dict 키와 일치시켜, 570개 키의 사전학습 가중치 (temp/monai.pt)를 load_state_dict(strict=True) 로 직접 로드할 수 있도록 설계하였다. 풀 모델의 총 파라미터 수는 **11,450,828**개다.

3.2 경량 모델: 인코더 깊이 축소

경량 모델 monai_mini 는 풀 모델과 동일한 전체 구조·채널 폭·디코더를 유지하면서 **인코더의 MBConv 블록 수만 절반으로 축소**한 버전이다. 각 스테이지의 블록 수를 $\text{ceil}(n/2)$ 로 줄여 총 블록 수를 23개에서 13개로 감소시켰다(축소율 56.5 %).

표 4. 스테이지별 블록 수: 풀 모델 vs 경량 모델

스테이지	출력 채널	풀 블록 수	경량 블록 수
0	16	2	1
1	24	3	2
2	48	3	2
3	88	4	2
4	120	4	2
5	208	5	3
6	352	2	1
합계		23	13

설계 근거: 채널 폭(width)을 유지한 이유는, 폭을 줄이면 스킵 연결 채널 수가 변해 디코더 구조 전체를 재설계해야 하기 때문이다. 블록 수만 줄이면 스킵 연결 채널(16/24/48/120/352)이 그대로 유지되어 디코더와 분할 헤드를 전혀 수정하지 않아도 된다. 또한 디코더의 연산량은 인코더에 비해 작고, 디코더를 줄이면 고주파 공간 정보 복원 능력이 저하되어 팁 위치 정밀도에 직접적인 악영향을 준다. 따라서 인코더 깊이만 축소하는 것이 속도-정확도 균형에서 가장 유리하다고 판단하였다. 경량 모델의 총 파라미터 수는 **5,502,870개**로 풀 모델의 48.1 %다. 블록을 56.5 % 줄였음에도 절감률이 48 %에 그치는 이유는 디코더·분할 헤드가 전체 파라미터의 상당 부분을 차지하기 때문이다.

3.3 학습 (Training)

손실 함수: 모델 출력 채널 1에 sigmoid를 적용한 값과 거리 기반 히트맵 타겟 사이의 평균제곱오차(MSE)를 최소화한다.

```
loss = MSE(sigmoid(pred[:, 1]), target)
```

전이 학습: §3.1의 MONAI 호환 설계를 통해 EfficientNet-B2 + U-Net 사전학습 가중치를 초기값으로 사용한 뒤, 복강경 수술 데이터셋으로 전체 네트워크를 파인튜닝한다.

데이터 증강: 학습 시 다음 무작위 증강을 순차 적용하며, 공간 변환은 이미지와 타겟 히트맵에 동시 적용된다. 검증·평가 시에는 Resize와 Normalize만 적용한다.

표 5. 학습 데이터 증강 파이프라인

변환	확률	파라미터
HorizontalFlip	0.5	—
VerticalFlip	0.2	—
Affine	0.6	이동 $\pm 5\%$, 스케일 0.85–1.15, 회전 $\pm 20^\circ$
RandomResizedCrop	0.5	scale 0.7–1.0, 종횡비 $\pm 10\%$
Resize	항상	480 × 736 px
ColorJitter	0.6	밝기·대비 ± 0.3 , 채도 ± 0.2 , 색상 ± 0.05
GaussianBlur	0.3	kernel 3–7
GaussNoise	0.3	—
Normalize	항상	ImageNet mean/std

최적화 설정: 옵티마이저는 Adam(lr=1e-4), 학습률 스케줄러는 CosineAnnealingLR(T_max=epochs)을 에포크 종료 시 step한다. 기본 학습 설정은 30 에포크, 배치 크기 16이다. 매 에포크 종료 시 검증 손실이 개선되면 best.pt, 항상 last.pt를 모델 타입별 디렉터리(data/models/<model-type>/)에 저장한다. 두 모델은 동일한 손실 함수·데이터셋·증강 파이프라인·최적화 설정으로 학습되어 공정한 비교가 가능하다.

가정: 평가 결과 파일에는 실행 시각만 기록되어 있고 학습에 실제 사용한 에포크 수는 명시되어 있지 않다. 본 보고서는 학습 가이드에 정의된 기본 설정(30 에포크, 배치 16, Adam lr=1e-4, CosineAnnealingLR)을 기준 학습 구성으로 간주한다.

3.4 추론 및 피크 탐지

추론 시 모델 출력 채널 1의 sigmoid 히트맵에서 다음 알고리즘으로 팁 위치 후보(피크)를 추출한다.

- 임계값 적용:** 히트맵 값 $\geq \text{threshold}$ 인 화소만 남긴다.
- 연결요소 분석:** `scipy.ndimage.label` 로 이진 마스크의 연결요소를 식별한다.
- 피크 선택:** 각 연결요소에서 최대값 화소를 피크 후보로 선택한다.
- 비최대 억제(NMS):** 값이 높은 피크부터 처리하며, 이미 선택된 피크로부터 `nms-radius` 이내의 낮은 피크를 제거한다.

결과는 (x, y, confidence) 목록을 값 내림차순으로 정렬하여 반환한다.

3.5 평가 프로토콜

매칭: 각 GT 팁에 대해 전체 피크 후보 중 가장 가까운 후보를 선택하여 유클리드 픽셀 거리를 기록한다. 후보가 하나도 없으면 해당 GT 팁은 **miss**로 처리된다.

지표: 다음 지표로 정확도를 정량화한다.

표 6. 평가 지표 정의

지표	설명
Miss rate	예측 후보 없음으로 탐지 실패한 GT 팁 비율
Hit@10/20/50 px	매칭 거리가 각각 10/20/50 px 이내인 GT 팁 비율
Mean / Median dist	매칭된 팁의 평균·중앙값 픽셀 거리
P90 dist	픽셀 거리 90 백분위수

평가는 테스트 세트 전체(36,142 프레임)에 대해 기본 설정 `threshold=0.5` , `nms-radius=20 px` 로 수행하였다. 결과는 전체 지표·세션별 지표·실행 파라미터를 담은 `summary.json` 과 GT 팁 1개당 1행을 기록한 `per_tip.csv` 로 저장된다.

4. 실험 결과 (Results)

4.1 전체 성능 비교

테스트 세트(36,142 프레임, 도구 보유 프레임 30,929개, 도구 없는 프레임 5,213개(14.4 %), GT 팁 52,489 개) 기준 두 모델의 성능은 다음과 같다.

표 7. 폴 모델 vs 경량 모델 전체 성능 (threshold=0.5, NMS radius=20 px)

지표	monai (폴)	monai_mini (경량)	차이
Miss rate	2.97 %	3.20 %	+0.23 %p
Hit@10 px	38.10 %	29.61 %	-8.49 %p
Hit@20 px	64.96 %	62.00 %	-2.96 %p
Hit@50 px	80.95 %	80.16 %	-0.79 %p
Median dist	12.53 px	14.14 px	+1.61 px

세션	GT 팁 수	비중	Miss율 (폴/경량)	평균 거리 (폴/경량)
doctor_250723_094100	9,246	17.6 %	3.87 % / 4.46 %	37.97 / 39.58 px
전체	52,489	100 %	2.97 % / 3.20 %	39.76 / 41.35 px

세션 간 성능 편차가 두드러진다. 최우수 세션 doctor_250620_131843 (평균 거리 25.91 px)과 최저 세션 doctor_250702_084355 (53.75 px) 사이의 차이는 27.84 px로, 세션에 따라 성능이 약 2배 변동한다. 특히 doctor_250702_084355 는 전체 GT 팁의 10.6 %만 차지하면서 전체 miss의 18.3 %(폴 모델)를 발생시켜 명백한 **성능 병목 세션**이다. 두 모델의 세션별 순위가 동일하다는 점은, 이 편차가 모델 용량 부족이 아니라 **데이터 자체의 특성**(조명 조건, 도구 종류, 화면 구성, 오클루전 등)에서 기인함을 강하게 시사한다. 한편 전체의 46.1 %를 차지하는 지배적 세션 doctor_250702_101536 의 성능(평균 39.26 px)이 전체 평균(39.76 px)과 거의 일치하여, 이 세션이 사실상 전체 결과를 대표한다.

평균적으로 도구 보유 프레임당 GT 팁은 $52,489 / 30,929 \approx \mathbf{1.70}$ 개로, 상당수 프레임이 2개 이상의 도구를 포함한다. 다중 도구 상황에서의 피크 분리와 NMS 파라미터 설정이 정밀도에 영향을 줄 수 있다.

4.4 추론 속도 비교

CPU 환경에서 테스트 세트 임의 샘플 1,000건(seed=42, batch=16, workers=0)에 대해 추론 속도를 측정하였다. forward_time 은 모델 forward 연산만, wall_time 은 데이터 로딩·후처리를 포함한 종단 간 루프 시간이다.

표 9. 추론 속도 비교 (CPU, test 샘플 1,000건)

모델	파라미터 수	Forward / frame	Wall / frame	Forward FPS	Wall FPS
monai	11,450,828	277.00 ms	287.49 ms	3.61	3.48
monai_mini	5,502,870	204.57 ms	215.06 ms	4.89	4.65

경량 모델은 폴 모델 대비 forward 기준 **1.35배**, wall-clock 기준 **1.34배** 빠르다. 파라미터를 약 52 % 줄였음에도 속도 향상이 1.35배(약 26 % 단축)에 그치는 것은, 인코더 후반 스테이지의 고채널·저해상도 블록보다 디코더의 고해상도 연산이 전체 지연 시간에서 큰 비중을 차지하고, 디코더는 경량화 대상이 아니었기 때문으로 해석된다. 따라서 경량화의 실익은 메모리·파라미터 절감(약 절반)이 속도 이득(약 4분의 1 단축)보다 크다.

4.5 정확도-속도 트레이드오프 종합

표 10. 정확도-속도 트레이드오프 요약

관점	monai (풀)	monai_mini (경량)
정밀도 (Hit@10 px)	38.10 %	29.61 %
강건성 (Hit@50 px)	80.95 %	80.16 % (-0.79 %p)
파라미터	11.45 M	5.50 M (48 %)
CPU forward FPS	3.61	4.89 (1.35×)

경량 모델은 정밀 탐지(Hit@10 px)에서 8.49 %p를 희생하는 대신 파라미터를 절반으로, CPU 추론 시간을 약 26 % 단축한다. 거친 탐지(Hit@50 px)와 miss율의 손실은 1 %p 미만으로 작다. 따라서 정밀한 팁 위치가 필수적인 응용(예: 정밀 항법)에서는 풀 모델이, 대략적 위치 추적으로 충분하고 자원·지연 제약이 큰 응용(예: 임베디드 카메라 추종)에서는 경량 모델이 합리적 선택이다.

5. 도구 및 재현성 (Tooling and Reproducibility)

본 프로젝트는 학습·평가뿐 아니라 결과를 인터랙티브하게 검증할 수 있는 도구 일체를 제공한다.

- **bin/train-model** : 모델 학습(--model-type , --epochs , --batch-size , --lr , --resume).
- **bin/eval-model** : 테스트 세트 정량 평가(--model-type , --threshold , --nms-radius). 결과를 summary.json · per_tip.csv 로 저장.
- **bin/compare-speed** : 두 모델의 추론 속도 비교(--num-samples , --batch-size).
- **bin/tooltip-detector** : 학습된 모델로 데이터셋 프레임 또는 임의 이미지를 추론하고, 원본·히트맵·GT·예측·오차를 시각화하는 GUI. Threshold·NMS 슬라이더로 파라미터를 실시간 조정하고, 탐색한 프레임의 누적 Hit-rate·거리 통계를 집계한다. 상단 드롭다운으로 monai / monai_mini 를 전환할 수 있다.
- **bin/dataset-browser** : 원본 이미지·바운딩 박스·팁 마커·거리 히트맵을 시각적으로 탐색하는 GUI.




그림 1. bin/tooltip-detector GUI 화면. 학습된 모델로 복강경 프레임을 추론하여 원본·히트맵·예측 팁·GT·오차를 함께 시각화하며, Threshold·NMS 슬라이더로 후처리 파라미터를 실시간 조정할 수 있다.

환경은 Python 3.12 이상, uv 패키지 매니저, CUDA 12.8 호환 GPU를 기준으로 하며, uv sync 로 의존성을 설치하고 uv run python -m ... 으로 실행한다. per_tip.csv 는 GT 팁 단위의 상세 기록(좌표·예측·거리·탐지 여부)을 제공하여, miss 프레임 추출, 오차 히스토그램, 세션·구간별 성능 집계 등 사후 분석을 가능하게 한다.

6. 논의 (Discussion)

6.1 거리 기반 히트맵의 효과

거리 기반 히트맵은 도구의 길쭉한 형태 정보를 학습 신호에 통합하여, 절반 이상의 GT 팁을 12–14 px 이내로 정확히 예측하는 양호한 기본 성능을 끌어냈다. 도구 영역 전반에 그래디언트를 부여한 설계 덕분에 학습이 안정적으로 수렴하고, 팁 근방에 최댓값이 집중되어 피크 위치가 곧 팁 위치가 되도록 유도하는 의도가 결과로 확인된다.

6.2 정밀도 한계와 오탐의 양극화

가장 두드러진 한계는 정밀 탐지율(Hit@10 px)이 풀 모델 기준 38.10 %에 머문다는 점이다. miss율은 3 % 안팎으로 낮아 "팁 후보를 찾는 능력"은 양호하나, "찾은 위치의 정확도"가 부족하다. 오차 분포의 이중 구조(중앙

값 대비 약 3배의 평균, P90 111 px)는 소수의 심각한 오탐이 정밀도를 지배함을 보여준다. 이러한 오탐은 오클루전, 조명 변화, 도구 간 혼선, 배경의 유사 구조 등에서 잘못된 위치에 강한 피크가 형성되는 경우일 가능성이 높으며, $\text{dist} > 50 \text{ px}$ 사례에 대한 시각적 원인 분석이 필요하다.

6.3 세션 의존성

세션 간 성능 편차(평균 거리 25.91–55.96 px)가 모델 종류와 무관하게 동일한 순위를 보인다는 사실은, 성능 변동의 원인이 모델 용량이 아니라 데이터 분포에 있음을 가리킨다. 특히 병목 세션 `doctor_250702_084355` 는 비중 대비 miss 기여도가 약 1.7배로, 이 세션의 장면 특성 분석과 표적 보강 학습이 전체 성능 개선의 우선 과제다.

6.4 경량화의 의의

경량 모델은 파라미터를 절반으로 줄이면서 거친 탐지 성능(Hit@50 px, miss율)을 거의 보존하였다. 정밀도 손실이 인코더 깊이 축소에 집중적으로 나타난 점은, 향후 경량화 시 인코더 후반 스테이지보다 정밀도에 민감한 부분을 보호하는 방향(예: 지식 종류, 디코더 보존형 가지치기)이 유효할 수 있음을 시사한다. 다만 속도 이득(1.35배)이 파라미터 절감(약 2배)에 미치지 못하는 것은 디코더가 지연의 주요 원인이기 때문으로, 실시간성이 목표라면 디코더의 효율화도 함께 검토해야 한다.

7. 한계 (Limitations)

- 평가 설정의 단일성:** 모든 정량 평가는 `threshold=0.5` , `nms-radius=20 px` 단일 설정에서 수행되었다. 정밀도가 낮은 점을 고려할 때 임계값·NMS 반경에 대한 민감도 분석(sweep)이 수행되지 않은 것은 한계다.
- 자동 생성 라벨의 미검증성:** 학습·평가의 기준이 되는 분할 마스크와 팁 어노테이션은 사전학습 모델 추론과 contour 휴리스틱으로 생성된 반자동 라벨로, 사람이 검증한 정답 대비 정확도가 측정되지 않았다 (§2.1). 따라서 본 보고서의 모든 정확도 수치(miss율, Hit-rate, 거리 등)는 불완전한 기준값에 대한 상대 성능이며, 라벨 자체의 오차(휴리스틱 실패, 과분할, test 1건 누락 등)가 평가에 섞여 들어갈 수 있다.
- 분할 방식과 시간적 누수:** 분할이 영상 단위가 아니라 영상 내부의 무작위 셔플로 이뤄져, 같은 영상의 인접 프레임이 train과 test에 동시에 존재할 수 있다(시간적 누수 소지). 또한 5편 영상이 모든 스플릿에 공유되므로 미지의 새 영상에 대한 일반화 성능(leave-video-out)은 측정되지 않았다.
- 학습 구성의 불완전한 기록:** 실제 사용한 에포크 수 등 학습 하이퍼파라미터가 결과 파일에 기록되어 있지 않아 기본값을 가정하였다 (§3.3).
- 속도 측정 범위:** 속도는 CPU·batch 16·단일 시드에서만 측정되었으며, GPU 추론 속도, 배치 크기 변화, 분산(variance)에 대한 측정은 포함되지 않았다.
- 정밀도 미달:** Hit@10 px가 38 %(풀)·30 %(경량)에 그쳐, 정밀 위치가 요구되는 임상 응용에 직접 적용하기에는 추가 개선이 필요하다.

8. 향후 연구 (Future Work)

분석에서 도출한 개선 방향을 우선순위와 함께 정리한다.

표 11. 향후 개선 방향

우선순위	방향	근거
상	병목 세션(doctor_250702_084355) 오류 패턴 분석 및 보강 학습	miss율·평균 거리 모두 최하위, 비중 대비 miss 기여 약 1.7배
상	threshold·NMS 민감도 분석 (threshold 0.3–0.4, NMS 10–15 px)	Hit@10 px가 낮아 후처리 민감도 개선 여지
중	dist > 50 px 오탐 사례 시각적 원인 분석	긴 꼬리 분포 원인(오클루전·조명·배경 혼선) 규명
중	다중 도구 프레임 성능 별도 집계	평균 1.70개/프레임, 피크 분리 실패 가능성 점검
중	자동 생성 라벨의 사람 검수·정량 검증	평가 기준값의 신뢰도 확보(라벨 IoU·팁 오차 측정)
중	영상 단위 분할(leave-video-out) 교차 평가	시간적 누수 차단 및 미지 영상 일반화 성능 정량화
하	경량 모델 정밀도 회복(지식 증류, 디코더 효율화)	정밀도 손실의 인코더 집중·디코더 지연 병목 대응

9. 결론 (Conclusion)

본 연구는 복강경 수술 영상의 수술도구 팁 탐지를 거리 기반 히트맵 회귀 문제로 정식화하고, MONAI 호환 EfficientNet-B2 + U-Net 분할 네트워크와 그 경량 변형을 18만여 프레임 규모의 데이터셋으로 학습·평가하였다. 풀 모델은 테스트 세트에서 miss율 2.97 %, Hit@50 px 80.95 %를 달성하여 도구 영역 수준의 팁 위치 추정에는 충분한 성능을 보였으나, 정밀 탐지(Hit@10 px 38.10 %)에는 한계를 드러냈다. 경량 모델은 파라미터를 절반으로 줄이면서 거친 탐지 성능을 거의 보존하고 CPU 추론을 1.35배 가속하여, 정밀도 손실을 감수할 수 있는 자원 제약 환경에 적합함을 확인하였다.

핵심 발견은 세 가지다. **첫째**, 두 모델 모두 오차 분포가 이중 구조를 이루어 소수의 심각한 오탐이 정밀도를 지배한다. **둘째**, 세션 간 성능 편차가 모델과 무관하게 일관되어 성능 병목이 데이터 특성에 기인한다. **셋째**, 경량화의 영향은 정밀 탐지에 집중되며 속도 이득은 디코더 지연으로 인해 파라미터 절감에 미치지 못한다. 향후 병

목 세션 분석, 후처리 민감도 튜닝, 오탐 원인 규명을 통해 정밀 탐지율을 끌어올리는 것이 임상 응용을 향한 핵심 과제다.

부록 A. 실험 환경 및 설정 요약

항목	값
데이터셋 규모	180,706 프레임 (train 108,424 / val 36,140 / test 36,142)
입력 해상도	736 × 480 px (RGB)
모델 (풀)	EfficientNet-B2 + U-Net, 11,450,828 파라미터
모델 (경량)	인코더 13블록, 5,502,870 파라미터 (48.1 %)
손실 함수	MSE(sigmoid(pred[:,1])), 거리 히트맵 타겟)
옵티마이저	Adam, lr=1e-4
스케줄러	CosineAnnealingLR (T_max=epochs)
학습 설정(기본)	30 epochs, batch 16
평가 설정	threshold=0.5, NMS radius=20 px
속도 측정	CPU, test 1,000건, batch 16, seed 42

부록 B. 결과 데이터 출처

파일	내용
data/results/monai/summary.json	풀 모델 평가 결과 (2026-06-29)
data/results/monai_mini/summary.json	경량 모델 평가 결과 (2026-06-30)
data/results/speed-comparison.json	추론 속도 비교 (2026-06-30)
data/results/<model>/per_tip.csv	GT 팁 단위 상세 기록

상세 분석 문서: docs/eval-results-monai.md , docs/eval-results-monai_mini.md , docs/model-monai.md , docs/model-monai_mini.md , docs/dataset-guide.md , docs/train-guide.md , docs/eval-guide.md .